



Escuela
Politécnica
Superior

Extracción y Estructuración de Contenido Lingüístico en PDFs para la Preservación de Lenguas Mayas



Máster en Inteligencia Artificial

Trabajo Fin de Máster

Autor:

Elías Alfonso Carrasco Guerrero

Tutor:

Juan Antonio Pérez Ortiz

Setiembre 2025



Universitat d'Alacant
Universidad de Alicante

Digitalización, estructuración y preservación lingüística de gramáticas mayas minorizadas mediante inteligencia artificial multimodal

Automatización de la preservación de lenguas minorizadas: un enfoque basado en modelos de lenguaje y marcado XML

Autor

Elías Alfonso Carrasco Guerrero

Directores

Juan Antonio Pérez Ortiz

Departamento de Lenguajes y Sistemas Informáticos



MÁSTER EN INTELIGENCIA ARTIFICIAL



Escuela
Politécnica
Superior



Universitat d'Alacant
Universidad de Alicante

Alicante, 31 de mayo de 2026

Resumen

La aplicación desarrollada para este Trabajo de Fin de Máster consiste en un software modular programado en Python que se ejecuta desde la terminal de comandos. Su función principal es automatizar la extracción de texto y la comprensión visual de páginas en formato PDF pertenecientes a gramáticas de lenguas mayas. El sistema inyecta ejemplos estructurados de entrada y salida (few-shot) junto a un prompt especializado directamente en la memoria de la API de Gemini, logrando que el modelo de Inteligencia Artificial entienda la disposición tipográfica original y devuelva la información totalmente organizada en un archivo XML con etiquetas semánticas personalizadas (como `<morpheme.analysis>` o `<syntactic.analysis>`). Posteriormente, el pipeline procesa este archivo XML para generar de forma automática un documento en LaTeX que se compila para reconstruir la obra original en un nuevo archivo PDF con un acabado editorial profesional. El objetivo último es transformar "papel digital" estático en un conjunto de datos estructurados de alta precisión (Gold Standard) que sirva como combustible indispensable para que, en el futuro, otras Inteligencias Artificiales puedan entrenarse y aprender idiomas minorizados de bajos recursos computacionales. Este Trabajo de Fin de Máster aborda la problemática de la digitalización y estructuración de gramáticas normativas de lenguas mayas minorizadas (como Kaqchikel, K'iche' y Mam), cuyos documentos originales presentan estructuras tipográficas complejas que dificultan el procesamiento mediante técnicas de OCR convencionales. Se propone y desarrolla un sistema automatizado basado en Modelos de Lenguaje de Gran Tamaño (LLMs) a través de la API de Gemini, integrado en un pipeline modular desarrollado en Python. Con este flujo se consigue mitigar la pérdida de información semántica y espacial inherente a los métodos planos tradicionales, salvaguardando recursos científicos de alto valor como las glosas interlineales. La metodología se fundamenta en la transformación de documentos PDF en datos estructurados bajo el estándar XML, garantizando la integridad jerárquica mediante la definición de un Documento de Definición de Tipo (DTD) y el desarrollo de módulos específicos de corrección estructural (`xml.corrector.py`). El núcleo de la investigación se centra en un estudio empírico sobre el parámetro de temperatura del modelo, evaluando su impacto en la precisión y estabilidad del sistema bajo una estricta economía de tokens impuesta por las limitaciones de cuota del entorno operativo. Los resultados experimentales demuestran la existencia de un "punto dulce" (sweet spot) en temperaturas de 0.1 y 0.25, donde se alcanzan precisiones superiores al 90

Palabras clave: Inteligencia Artificial, LLM, Gemini API, Lenguas Mayas, Digitalización, XML, Procesamiento de Lenguaje Natural, OCR Estructurado.

Motivación y justificación

La preservación de la diversidad lingüística constituye uno de los desafíos más críticos en la era de la información. Las lenguas minorizadas, en particular aquellas pertenecientes a la familia maya como el Kaqchikel, el K'iche, el Mam y el Kanjobal, representan un patrimonio cultural de valor incalculable. Sin embargo, su supervivencia no sólo depende de su uso oral, sino también de la disponibilidad y accesibilidad de recursos académicos y normativos en formatos digitales modernos. En este contexto, la Academia de Lenguas Mayas de Guatemala (ALMG) desempeña un papel crucial como entidad rectora en la promoción y estandarización de estos idiomas. A través de su repositorio institucional de documentos (disponible en <https://almg.org.gt/documentos/>), la ALMG ha realizado un esfuerzo significativo por poner a disposición del público gramáticas normativas y textos de referencia, tal y como se muestra en la figura 1. No obstante, gran parte de este conocimiento se encuentra consignado en archivos PDF que, si bien facilitan la difusión, actúan esencialmente como "papel digital": una representación estática de la información que carece de estructura semántica.

Por ejemplo, ya en marzo de 2025, tuvieron una actualización de la web en la que eliminaron el 70Esta limitación impide que los datos lingüísticos (ejemplos gramaticales, reglas sintácticas, morfología) puedan ser procesados automáticamente por herramientas computacionales, buscadores especializados o sistemas de aprendizaje profundo. La motivación técnica de este trabajo radica, por tanto, en la superación de las barreras impuestas por el reconocimiento óptico de caracteres (OCR) convencional sobre este corpus específico de la ALMG, para generar corpus con morfologías clasificadas para entrenamiento de modelos. Las gramáticas lingüísticas de estas lenguas presentan una complejidad tipográfica elevada, que incluye tablas anidadas, glosas interlineales y estructuras jerárquicas que los sistemas tradicionales suelen interpretar de manera errónea. Ante este escenario, surge la oportunidad de emplear Modelos de Lenguaje de Gran Tamaño (LLMs), para comprender la arquitectura lógica de estos documentos institucionales y transformarla en datos estructurados bajo el estándar XML. Este proyecto busca proporcionar una solución eficiente que reduzca la carga de trabajo manual en la digitalización del patrimonio de la ALMG, garantizando que la información sea interoperable, consultable y apta para la generación de documentación científica profesional mediante LaTeX.

Documentos Publicados



Según la Ley de la Academia de las Lenguas Mayas de Guatemala, establece que dentro de sus funciones está traducir y publicar, previo cumplimiento de las leyes de la materia, códigos, leyes, reglamentos y otros textos legales o de cualquier naturaleza que se juzgue necesario a los idiomas Mayas.

Además de crear, implementar e incentivar programas de publicaciones bilingües y monolingües, para promover el conocimiento y uso de los idiomas mayas para fortalecer los valores culturales.

Para lo anterior la Academia ha realizado varias publicaciones en diferentes idiomas Mayas, y algunas de ellas se presentan a continuación:

Para mayor información pueden ingresar a la página de [contacto](#)

AllSearch				
Comunidad Lingüística	Tipo de Documento	Nombre del Documento (Idioma Maya)	Nombre del Documento (Idioma Español)	Descarga
Achi	Texto	jik'ib'al Ub'ee Tz'iib'Maya'ch'a'teem Achi	Gramática _Normativa Idioma Maya Achi	
Akateka	Texto	ik'ti'ey Skuyb'anil	Fábulas	
Akateka	Texto	ik'ti'ey Skuyb'anil	Fábulas (2024)	
Akateka	Texto	xolilal Yelalil Ya'ley Ti'e Akateko	Gramática Descriptiva Akateka	
Akateka	Texto	Tz'ib'b'il qichmam Akateka	Literatura Maya Akateka	
Akateka	Texto	Sb'i K'ultajb'al yet Qichmam Akateko	Toponimias Maya Akateko	

Figura 1: Web de la ALMG

Agradecimientos

*A mi familia por estar ahí en todo momento.
A mi pareja por ayudarme en todo lo que puede y más.
A mi madre por dedicar su vida a sus hijos.
A mi padre por animarme con mi carrera en la ciencia.
A mis compañeros del Santander por guiarme y enseñarme cómo desarrollar software.
Sin ellos no habría podido hacer este trabajo.*

Pues hemos nacido para colaborar, al
igual que los pies, las manos, los
párpados, las hileras de dientes,
superiores e inferiores. Obrar, pues,
como adversarios los unos de los otros
es contrario a la naturaleza.

Marco Aurelio (Meditaciones)

Solo los que se quemaron con el fuego
aprendieron a usarlo.

Andrés Pedreño Muñoz
Cofundador de Torre Juana OST

Índice general

Resumen	v
1 Introducción	1

Índice de figuras

1	Web de la ALMG	VIII
---	--------------------------	------

Índice de tablas

Índice de Listados

1 Introducción

En la actualidad, la gestión eficiente de la información y la documentación es una necesidad crítica para muchas organizaciones. Empresas, instituciones y proyectos a gran escala dependen de bases de datos robustas para almacenar, organizar y acceder rápidamente a grandes volúmenes de documentos.

Sin embargo, uno de los desafíos más comunes es asegurarse de que los documentos estén correctamente almacenados, organizados y accesibles únicamente por el personal autorizado. Por ejemplo, el equipo de tecnologías de la información no debería tener acceso a la información contenida en un contrato de crédito.

A esto se suma que, en muchas empresas, la generación de documentos se delega a proveedores externos, lo que implica que el flujo de un documento pase por varias etapas. Esto aumenta el riesgo de que se produzcan pérdidas o errores en el almacenamiento. En este contexto, es crucial contar con herramientas que permitan realizar verificaciones automáticas y comprobar que los documentos se encuentran correctamente guardados.

Otro aspecto relevante es la necesidad de proteger la información confidencial. Para evitar comprometer la seguridad de los datos de clientes y empresas, es indispensable que las herramientas puedan verificar el correcto almacenamiento de los documentos sin acceder a su contenido o metadatos. Esta capacidad es fundamental para mantener la integridad y confidencialidad de la información.

El desarrollo de aplicaciones web con tecnologías modernas como Spring Boot, JPA y Thymeleaf ha cobrado gran relevancia debido a su capacidad para ofrecer soluciones eficientes en la gestión de bases de datos y el procesamiento de información. Estas tecnologías permiten crear aplicaciones ágiles y seguras, que pueden realizar operaciones complejas de filtrado, validación y acceso a datos en tiempo real.

La aplicación web propuesta en este proyecto tiene como objetivo facilitar el filtrado y la validación de documentos almacenados. Con este fin, se desarrollará una interfaz con una tabla que muestre campos del documento como su identificador y la hora a la que se almacenó en la base de datos, asegurando así su correcto almacenamiento y la consistencia de los datos, sin poder acceder a campos del documento con información confidencial.

Todo el código de la aplicación SIDManager está disponible en la plataforma GitHub de manera pública en el enlace a pie de página ¹. La aplicación sigue las indicaciones de la estrategia de software de código abierto (open source) de la Comisión Europea, como se puede ver en el enlace en el pie de página ².

¹<https://github.com/eliascarrasco1227/SIDManager>

²https://commission.europa.eu/about/departments-and-executive-agencies/digital-services/open-source-software-strategy_en#opensourcesoftwarestrategy

El nombre de esta aplicación, SIDManager, proviene de dos componentes. El primero, SID, corresponde con las siglas de Sistema de Impresión de Documentos, un conjunto de scripts y aplicaciones web que se encargan de la gestión, impresión, envío y modificación de documentos. El segundo componente, Manager, proviene del inglés y significa administrador, ya que es la web encargada de la administración de los documentos; es decir, sirve para verificar la situación de los documentos y ver si se han almacenado correctamente en la base de datos.

Finalmente, esta herramienta está diseñada para simplificar el acceso y la gestión de datos en entornos empresariales, priorizando la seguridad, el rendimiento y la escalabilidad. Al mismo tiempo, desacopla la lógica de negocio de la aplicación, ya que no necesita acceder al contenido de los documentos.

Con la implementación de Spring Security, se garantiza un acceso seguro, mientras que log4j permite un seguimiento detallado de las operaciones y posibles incidencias. De este modo, el proyecto ofrece una solución accesible y eficiente para cualquier empresa o individuo que necesite verificar y gestionar documentos, sin recurrir a equipos especializados o productos de software externos.